

# CausalVerify 端到端流程（泳道图）

End-to-End Pipeline (Swim-Lane View)

泳道 A: 262 篇真实论文（广度）  
Lane A: 262 Real Papers — Breadth

泳道 B: 100 个合成 DGP（深度 · 核心）  
Lane B: 100 Synthetic DGPs — Depth (core)

## 阶段 0: 数据收集

## Stage 0: Data Collection

OpenAlex 查询 → 顶级期刊 / 方法 / 引用数  
OpenAlex query → top journals / methods / citations

人工筛选 → 262 篇候选论文  
Manual filter → 262 candidate papers

Core 57 (作者读全文) · Expansion + Extended 205 (GPT-4o 辅助)  
Core 57 (full-text read) + Expansion/Extended 205 (GPT-4o assisted)

→ 262 × paper\_XX.json

NumPy DGP 函数 (seed=42 / 123)  
NumPy DGP functions (fixed seeds)

生成 100 个合成 CSV (1600+ 行 / 每个)  
Generate 100 synthetic CSVs (1600+ rows each)

s01-s30 手写场景 · s31-s100 GPT-4o 生成  
s01-s30 hand-written · s31-s100 GPT-4o generated

→ 100 × sXX.json + 100 × CSV

## 阶段 1: LLM 调用

## Stage 1: LLM Call

run\_exp\_a.py  
组装 7 章节 prompt (识别策略 / R 代码 / 预期等)

调用 6 个前沿模型: Opus · Sonnet · GPT-4o · o3 · Kimi · Gemini  
Call 6 frontier models

→ 1,572 输出 JSON (262 × 6)

run\_exp\_b.py  
组装 3 章节 prompt + CSV 预览 + 文件路径

调用 6 个前沿模型 (同上)  
Call same 6 frontier models

→ 600 输出 JSON (100 × 6)

## 阶段 2: 自动评分

## Stage 2: Automated Scoring

auto\_score\_exp\_a.py

L1 输出非空?  
L3 方法识别 (章节感知关键词) + 方向预测

L4 4 种评分器 (S1/S2/S3/S4) 测脆弱性  
L4 four scorers test fragility

→ auto\_scores.csv · multi\_scorer\_l4.csv

★ score\_l2b\_plus.py (论文核心 / paper's core)

L1 输出非空?      L2a 提取 R 代码  
L2b Rscript 真正执行 (60s 超时)

L2b+  $|\hat{\beta} - \beta^*| / |\beta^*| < 0.5 \rightarrow$  系数正确  
L2b+ relative error < 50% → coefficient correct

→ l2b\_plus\_scores.csv · summary.json

## 阶段 3: 排名 & 统计分析（两泳道汇合）

## Stage 3: Ranking & Analysis (lanes merge)

head\_to\_head\_ranking.py  
以 L2b+ 为真实排名 · 6 模型 × 多指标 Kendall  $\tau$  / Spearman  $\rho$

bootstrap\_head\_to\_head.py  
10,000 次 Bootstrap → 95% CI L2b:  $\tau = +0.73$  · L4:  $\tau \approx 0$

→ head\_to\_head\_ranking.json + bootstrap.json

## 阶段 4+5: 图表生成 & 论文编译

## Stage 4+5: Figures & Paper Compilation

图表生成 / Figure Generation  
fig2\_headline · fig3\_dotplot · fig4\_cascade · fig\_error\_cdf

Docker texlive + pdflatex ×3 + bibtex  
neurips\_v10.tex → neurips\_v10.pdf

✓ 最终成果 / Final Output  
neurips\_v10.pdf (29 pages · 331 KB)

泳道 A: Exp A (262 papers)

泳道 B: Exp B (100 DGPs)

汇合阶段: Merge stage

论文产出: Paper output